

Data Quality

a Open Beauty Facts

*¿Cómo identificar qué productos tienen datos fiables
para su uso en análisis o modelos futuros?*

MayeLabs · github.com/MayeLabs/anban_explorador_data

world.openbeautyfacts.org

El Problema

Open Beauty Facts es una plataforma colaborativa donde cualquier persona puede registrar productos cosméticos. Esa apertura es su mayor valor, pero también su mayor riesgo:

Nadie verifica que los datos subidos sean fiables.



Incompletos

Campos clave vacíos:
sin categoría, sin país



Duplicados

Mismo producto
registrado varias veces



Inconsistentes

Categorías y países
en idiomas mezclados

La Solución — Pipeline de 4 Fases

Pipeline automatizado en Python · datos crudos → catálogo evaluado, segmentado y clasificable

I

01_ingestion_ETL.i pynb

Ingesta + ETL

Descarga 50.000 productos
vía API en 10 lotes → SQLite

II

02_data_qa_layer.ipynb

Data Quality Layer

20 métricas por producto
product_quality_score 0.0–1.0

III

03_eda.ipynb

EDA

Distribuciones, correlaciones
y perfiles por marca

IV

04_cluster_ml.ipynb

Clustering + Clasificador

KMeans k=5 · Random Forest
para clasificar nuevos productos

Product Quality Score

Un número entre 0.0 y 1.0 por producto — construido en 3 dimensiones ponderadas

50%

Compleitud crítica

¿Están los 4 campos
clave rellenos?

35%

Calidad ingredientes

Proporción de ingredientes
reconocidos

15%

General + Taxonomía

Compleitud general +
consistencia idioma

Fórmula: Si duplicado $\rightarrow$ score = 0.0 · Sin Ingredientes $\rightarrow$ score = -1

$\text{compl_critical_ratio} \times 0.50 + \text{ingredients_quality_score} \times 0.35 + (\text{completeness} + \text{taxonomy}) \times 0.15$

⚠️ Un duplicado o la ausencia total de ingredientes invalida el score independientemente del resto de dimensiones

¿Por qué $k=5$?

Se evaluaron $k=2$ a $k=10$ con tres métricas de validación interna



Elbow (Inercia)

La curva se aplana a partir de $k=5$ — más clusters no aportan ganancia significativa

Silhouette

Máximo en $k=2$, pero $k=5$ mantiene un valor razonable con mayor interpretabilidad

Davies-Bouldin

Mínimo en $k=5$ — los clusters están bien separados y son compactos

Resultados — 5 Segmentos de Calidad

KMeans $k=5$ · PCA — 54.7% varianza explicada

🔍 Bien documentados

Score alto · datos completos

● Incompletos

Sin categoría · sin país

● Calidad mediocre


Datos parciales · ingredientes con problemas

🔍 Populares / duplicados

Alto engagement · nombres repetidos

🔍 Sin categorizar

Sin taxonomía · datos mínimos



Conclusiones

70.9%

no evaluable

29.1%


score válido

35.474 productos recibieron score -1 por ausencia total de ingredientes.
Del 29.1% válido, la calidad no es uniforme — **el catálogo no puede tratarse como dataset homogéneo.**

5

perfiles diferenciados — desde productos bien documentados con scores superiores a 0.8, hasta registros sin taxonomía ni datos mínimos.

Perfil de cada cluster (valores normalizados)



Problemas más frecuentes

~2.800

nombres duplicados

~1.600

conflicto de idioma
países vs categorías

~4.000

discrepancia
Sum > total ingredientes

Conclusiones

reutilizable

El Random Forest clasifica
nuevos productos
automáticamente

nueva descarga → mismo análisis
reproducibile



Matriz de confusión — Clasificador de clusters

True label	Bien documentados	510	0	1	1	9
	Incompletos	0	495	2	2	10
	Calidad mediocre	0	2	333	1	6
	Populares/duplicados	2	1	0	475	16
	Sin categorizar	5	8	3	1	1022
		Bien documentados	Incompletos	Calidad mediocre	Populares/duplicados	Sin categorizar
		Predicted label				

Sí es posible saber qué productos son fiables.

Asignando un `product_quality_score` a cada registro y segmentando el catálogo en 5 grupos diferenciados, se puede filtrar y decidir qué datos son usables — antes de que contaminen cualquier análisis.

github.com/MayeLabs/anban_explorador_data

MayeLabs · Bootcamp IA & Data Science ANBAN 2026